Data Warehouse

Laporan CB01 Eksplorasi Tools ETL

Disusun oleh:

Ahsanta Khalqi Imany	235150707111045
Pramudhia Ananda Kresna	235150707111044
Alfaril Dzaky Praptana	235170200111017
Muhammad Faza Husain Baihaqi	245150700111044
Muhammad Syauqi Syihabuddin	245150701111033

Dosen:

Niken Hendrakusuma Wardani, S.Kom., M.Kom.

Mata Kuliah:

Data Warehouse

Program Studi Teknologi Informasi

Fakultas Ilmu Komputer

Universitas Brawijaya

2026

1. KAJIAN TOOLS

1.1 Sejarah Singkat

Apache Hop adalah singkatan dari Hop Orchestration Platform. Perkembangannya bermula dari komunitas Kettle, metabolic data integration tool yang sebelumnya dikenal sebagai Pentaho Data Integration. Kettle diperoleh Pentaho, dan Pentaho sendiri diakuisisi Hitachi pada 2015 sehingga arah pengembangan Kettle tidak lagi sejalan dengan kepentingan pemilik perusahaan. Komunitas Kettle meneruskan pengembangan secara mandiri, dan kode Kettle sejak Desember 2005 telah tersedia secara terbuka dengan lisensi Lesser GPL, lalu berpindah ke lisensi Apache 2.0 sejak Januari 2012. Project Hop dikembangkan sebagai kelanjutan komunitas tersebut. Usulan inkubasi dikirim ke Apache Software Foundation pada 9 September 2020 dan diterima pada 24 September 2020, versi 1.0 rilis pada Oktober 2021, lalu Apache Hop graduasi menjadi proyek tingkat atas Apache pada Desember 2021.

1.2 Lisensi

Apache Hop memakai lisensi Apache License 2.0, yaitu lisensi permisif yang mengizinkan pemakaian, modifikasi, dan distribusi ulang, termasuk penggunaan komersial, dengan syarat penyebutan hak cipta dan pernyataan perubahan.

1.3 Arsitektur

Dokumentasi arsitektur resmi Apache Hop menyebut prinsip utamanya sebagai pemisahan metadata dari kode runtime dan tools. Seluruh pekerjaan orkestrasi didefinisikan sebagai metadata, dan metadata itu dapat diekspresikan dalam berbagai bentuk, seperti dokumen XML, dokumen JSON, basis data, atau antarmuka grafis. Pemisahan tersebut menghasilkan instalasi yang ramping, stateless, dan dapat dijalankan pada berbagai platform serta berbagai tahap siklus hidup, mulai dari pengembangan, pengujian, hingga produksi.

Apache Hop dibangun di atas fondasi Apache Beam, sehingga pipeline yang sama dapat dijalankan pada engine bawaan, Apache Spark, Apache Flink, atau Google Cloud Dataflow tanpa menulis ulang logika orkestrasi. Lima tools utama yang disediakan adalah Hop Gui untuk menyusun pipeline secara grafis, Hop Run untuk eksekusi baris perintah, Hop Config untuk mengelola konfigurasi instalasi, Hop Server untuk menjalankan pipeline sebagai layanan, serta Hop Web sebagai klien tipis untuk peramban.

1.4 Komponen Utama

Instalasi bawaan membawa ratusan plugin yang dapat dikurangi atau ditambah sesuai kebutuhan, sehingga ukuran instalasi tetap kecil dan pengembang dapat membuat plugin sendiri. Transform yang dipakai pada tugas ini ada enam, yaitu CSV file input, Microsoft Excel input, Table input, Unique rows (HashSet), Text file output, dan Table output.

Tabel 1.4.1. Komponen Apache Hop

Komponen	Fungsi
Project	Wadah sekumpulan pipeline, workflow, dan metadata yang saling berelasi

Environment	Kumpulan variabel yang dibedakan menurut nama, misalnya Development dan Production
Run configuration	Pasangan environment dan pipeline yang dijalankan
Pipeline	Rangkaian transform yang memproses data dari satu sumber ke output
Workflow	Rangkaian action yang menjalankan pipeline dan perintah lain secara berurutan
Transform	Unit kerja pemrosesan data, misalnya pembaca berkas, pencarian nilai, penyaringan, dan pengurutan
Action	Unit kerja pada workflow, misalnya menjalankan pipeline, mengeksekusi SQL, atau mengirim surel
Metadata connection	Definisi koneksi ke sumber data dan target
Hop Run	Tools eksekusi baris perintah untuk workflow dan pipeline

2. INSTALASI KONFIGURASI PERCOBAAN

Link video instalasi: dwhcb1.mp4

2.1 Spesifikasi Perangkat

Spesifikasi laptop yang dipakai: Intel Core i5-1155G7 dengan 4 inti dan 8 thread pada frekuensi 2,50 GHz, memori 8 GB dengan kapasitas terpasang 7,7 GB, dan penyimpanan SSD 224 GB dengan ruang bebas 38 GB. Kartu grafis berupa Intel Iris Xe dan NVIDIA GeForce MX450. Seluruh tools yang dipakai gratis atau sumber terbuka, sehingga ketentuan tugas terpenuhi.

Tabel 2.1.1. Spesifikasi perangkat yang digunakan

Kebutuhan	Versi yang dipakai	Peran
Apache Hop	2.19.0	Penyusun dan eksekutor pipeline ETL
Java	Oracle JDK 25.0.4	Runtime yang menjalankan engine Hop
PostgreSQL	18.1	Server basis data sumber dan target
Python	3.14.8	Generator berkas pipeline dan skrip verifikasi
Sistem operasi	Windows 11 Home 64-bit, macOS Tahoe 16.0.1	Lingkungan kerja kelompok

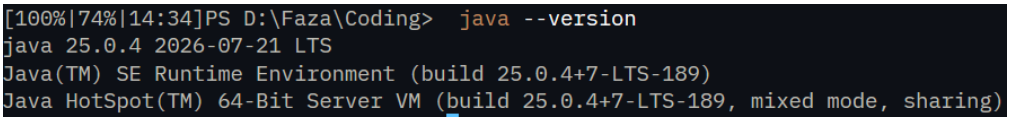
Pipeline pada Subbab 2.3 dibangun dan dijalankan pada perangkat kedua berbasis macOS. Repository project yang sama dipakai di kedua perangkat, dan perbedaan pengaturan koneksi ditangani lewat variabel environment (Subbab 2.2.4).

2.2 Persiapan Percobaan

2.2.1. Instalasi Java

Apache Hop 2.19.0 membutuhkan Java 21 sebagai versi minimum, dan versi 21 merupakan versi JVM yang resmi diuji oleh proyek. Pada mesin kerja dipakai Oracle JDK 25.0.4, dipasang dari paket untuk Windows x64, lalu variabel JAVA_HOME diarahkan ke folder instalasi dan folder bin ditambahkan ke variabel PATH. Pemeriksaan dengan perintah java -version menampilkan versi 25.0.4. Bila JRE lain dipakai, variabel HOP_JAVA_HOME dapat diarahkan ke JRE tertentu agar Hop memakai JVM khusus tanpa mengubah konfigurasi sistem. Dokumentasi Hop menandai Adoptium sebagai JVM yang memiliki masalah yang pernah dikonfirmasi, sehingga pemilihan OpenJDK 21 atau Oracle JDK menjadi pilihan yang lebih aman.

Gambar 2.2.1 Hasil perintah java -version



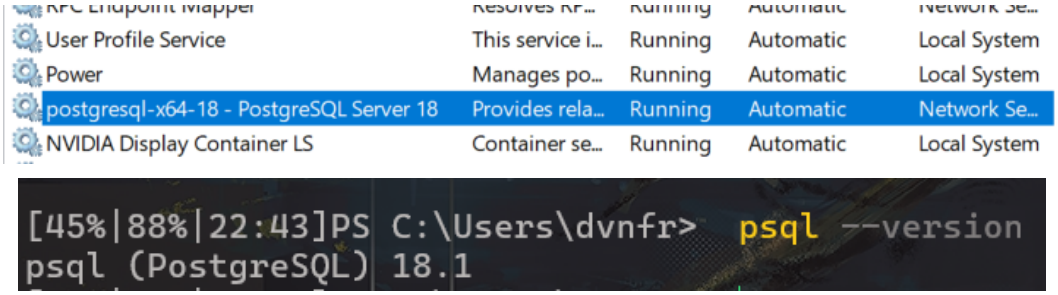
2.2.2. Instalasi PostgreSQL

Server PostgreSQL 18.1 dipasang dari berkas installer untuk Windows. Pada tahap instalasi, service Windows dikonfigurasi untuk berjalan otomatis, zona waktu lokal disetel ke Asia/Jakarta, dan port

default 5432 dipertahankan. Setelah instalasi selesai, service diperiksa dengan perintah sc query postgresql-x64-18 yang memberi status Running. Perintah psql --version dipakai untuk memastikan bahwa alat baris perintah tersedia, dan hasilnya versi 18.1.

Basis data sumber dan target dibuat terpisah. Basis data tokomaju_oltp memuat master pelanggan 180 baris sesuai skrip SQL yang tersedia, sedangkan basis data tokomaju_dw dipakai sebagai target pipeline ETL. Pembuatan pengguna, database, dan skema dilakukan oleh skrip setup_database.bat agar langkah yang sama dapat dijalankan ulang pada mesin lain.

Gambar 2.2.2 Hasil pemeriksaan service PostgreSQL dan versi psql



2.2.3. Instalasi Apache Hop

Apache Hop 2.19.0 diunduh dalam bentuk paket zip dari halaman unduhan resmi, lalu diekstrak ke folder Tools pada profil pengguna. Ekstraksi arsip dipilih karena tidak memerlukan hak administrator dan tidak mengubah registri sistem. Setelah ekstraksi, folder instalasi berisi skrip hop-gui.bat untuk antarmuka grafis, hop-run.bat untuk eksekusi baris perintah, dan folder lib yang berisi pustaka engine beserta plugin bawaan. Daftar isi folder instalasi ditampilkan pada tangkapan layar berikut.

Gambar 2.2.3 Tampilan antarmuka Apache Hop Gui yang sudah terbuka



2.2.4. Konfigurasi Koneksi Basis Data

Folder project didaftarkan pada Hop Gui melalui pemilih project di status bar kiri bawah, dengan nama project tokomaju dan project home menunjuk ke folder cb-etl-hop. Untuk project tersebut dibuat environment tokomaju yang memuat dua berkas konfigurasi, yaitu DW-config.json dan OLTP-config.json. Kedua berkas berisi variabel koneksi, sehingga setiap anggota cukup menyesuaikan nilai variabel di laptop masing-masing tanpa mengubah definisi koneksi.

Tabel 2.2.1. Variabel environment untuk koneksi basis data

Variabel (DW_ / OLTP_)	Nilai pada DW-config.json	Nilai pada OLTP-config.json
`*_HOSTNAME`	localhost	localhost
`*_PORT`	5432	5432
`*_DATABASE`	tokomaju_dw	tokomaju_oltp
`*_USERNAME`	postgres	postgres
`*_PASSWORD`		

Dua koneksi basis data kemudian didaftarkan pada metadata project. Koneksi **oltp** menuju database sumber tokomaju_oltp, sedangkan koneksi **dw** menuju database target tokomaju_dw. Seluruh isian koneksi memakai variabel, misalnya `${OLTP_HOSTNAME}`, `${OLTP_PORT}`, dan `${OLTP_DATABASE}`. Keduanya memakai driver PostgreSQL bawaan Hop versi 42.7.12 dan diuji dengan tombol Test.

2.2.5. Tabel Staging dan Rancangan Skema Data Warehouse

Hasil ekstraksi ditampung di tiga tabel staging pada tokomaju_dw, yaitu stg_penjualan, stg_produk, dan stg_pelanggan. Struktur tabel dibuat dari tombol SQL pada transform Table output, yang menghasilkan perintah CREATE TABLE sesuai kolom yang diterima. Seluruh kolom staging bertipe teks agar data mentah tersimpan apa adanya sebelum dibersihkan.

Skema bintang target untuk tahap lanjutan dirancang dalam skrip SQL pada folder sql project. Skrip tersebut membuat satu tabel fakta dan tiga tabel dimensi seperti pada Tabel 2.2.2. Pemuatan ke skema bintang belum dijalankan pada tugas ini, karena transformasi yang diminta berhenti pada penghapusan baris duplikat.

Tabel 2.2.2. Rancangan skema bintang tokomaju_dw

Tabel	Kunci	Kolom lain
dim_waktu	waktu_key (INTEGER, format yyyymmdd)	tanggal, hari, bulan, nama_bulan, kuartal, tahun
dim_produk	produk_key (SERIAL)	id_produk, nama_produk, kategori, merek
dim_pelanggan	pelanggan_key (SERIAL)	id_pelanggan, nama, jenis_kelamin, kota, provinsi, telepon

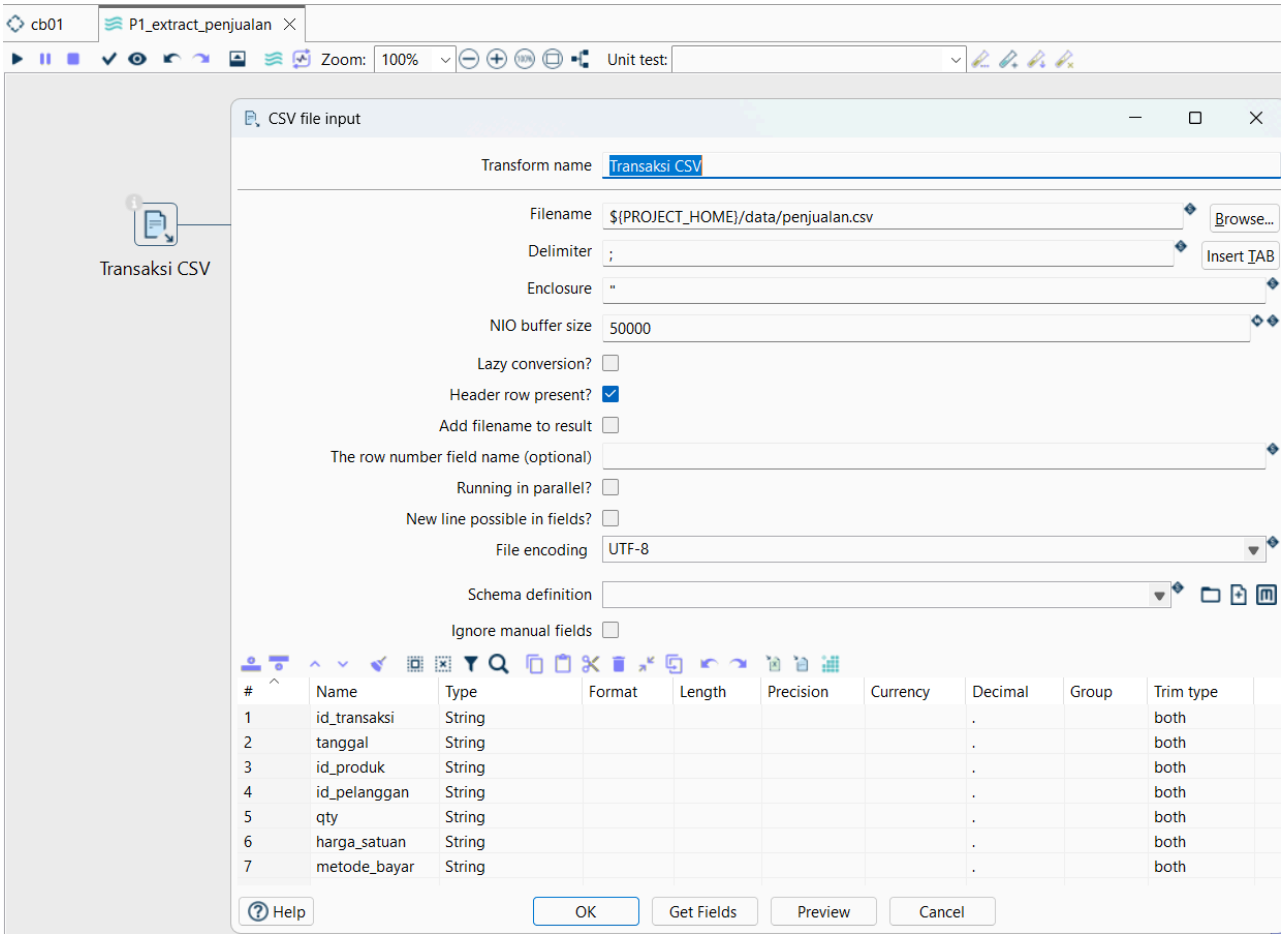
Tabel	Kunci	Kolom lain
fakta_penjualan	id_transaksi; FK waktu_key, produk_key, pelanggan_key	metode_bayar, qty, harga_satuan, total_penjualan

2.3 Langkah Percobaan

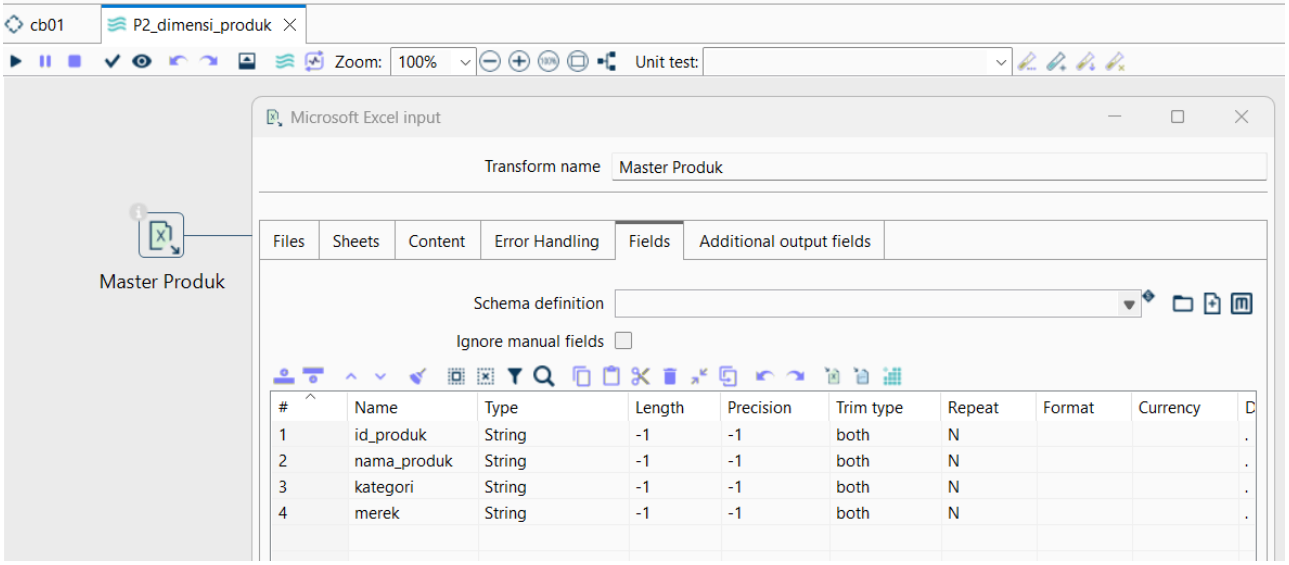
2.3.1. Tahap Extract

Setiap sumber data dibaca oleh satu pipeline. Pipeline extract_penjualan memakai transform CSV file input untuk membaca penjualan.csv dengan pemisah titik koma, enclosure tanda kutip, dan baris judul. Ketujuh kolom (id_transaksi, tanggal, id_produk, id_pelanggan, qty, harga_satuan, metode_bayar) dibaca bertipe String karena format tanggal dan harga masih bercampur. Pipeline extract_produk memakai transform Microsoft Excel input dengan engine Excel XLSX (Apache POI) pada sheet Produk, dan keempat kolomnya dibaca bertipe String. Pipeline extract_pelanggan memakai transform Table input dengan koneksi oltp dan kueri SELECT * FROM pelanggan.

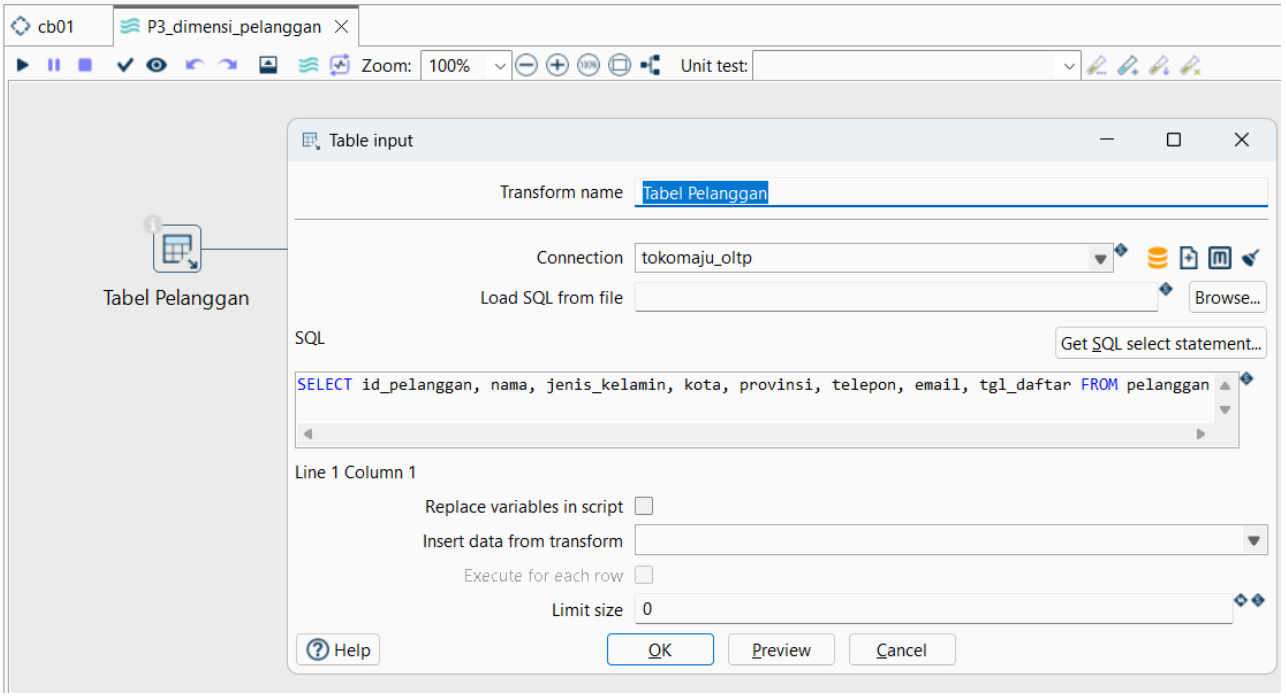
Gambar 2.3.1. (A) Input sumber data CSV



Gambar 2.3.1. (B) Input sumber data excel



Gambar 2.3.1. (C) Input sumber data pelanggan



2.3.2. Tahap Transform

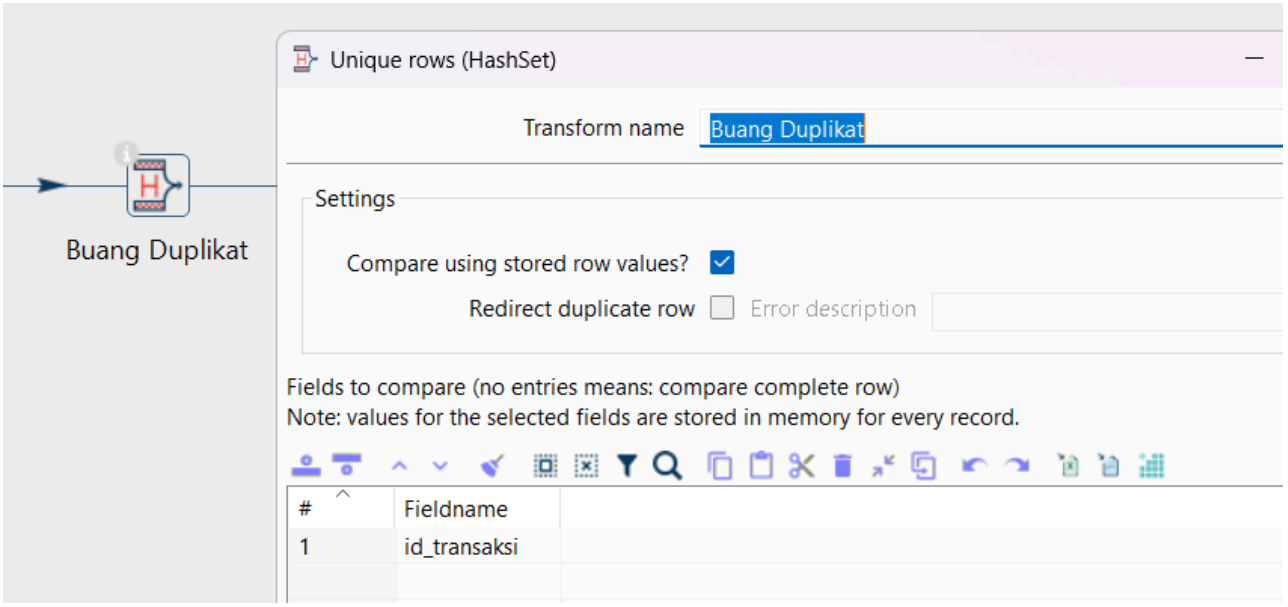
Transformasi pada tugas ini berhenti di penghapusan baris duplikat. Setiap pipeline memakai transform Unique rows (HashSet) dengan kunci id_transaksi untuk penjualan, id_produk untuk produk, dan id_pelanggan untuk pelanggan. Versi HashSet dipilih karena dapat membuang duplikat di posisi mana pun tanpa perlu mengurutkan data lebih dahulu. Pada pipeline extract_penjualan, opsi Redirect duplicate row diaktifkan sehingga baris duplikat dialihkan melalui hop error handling ke transform Text file output dan tersimpan sebagai bukti di folder output.

Tabel 2.3.1. Hasil penghapusan baris duplikat

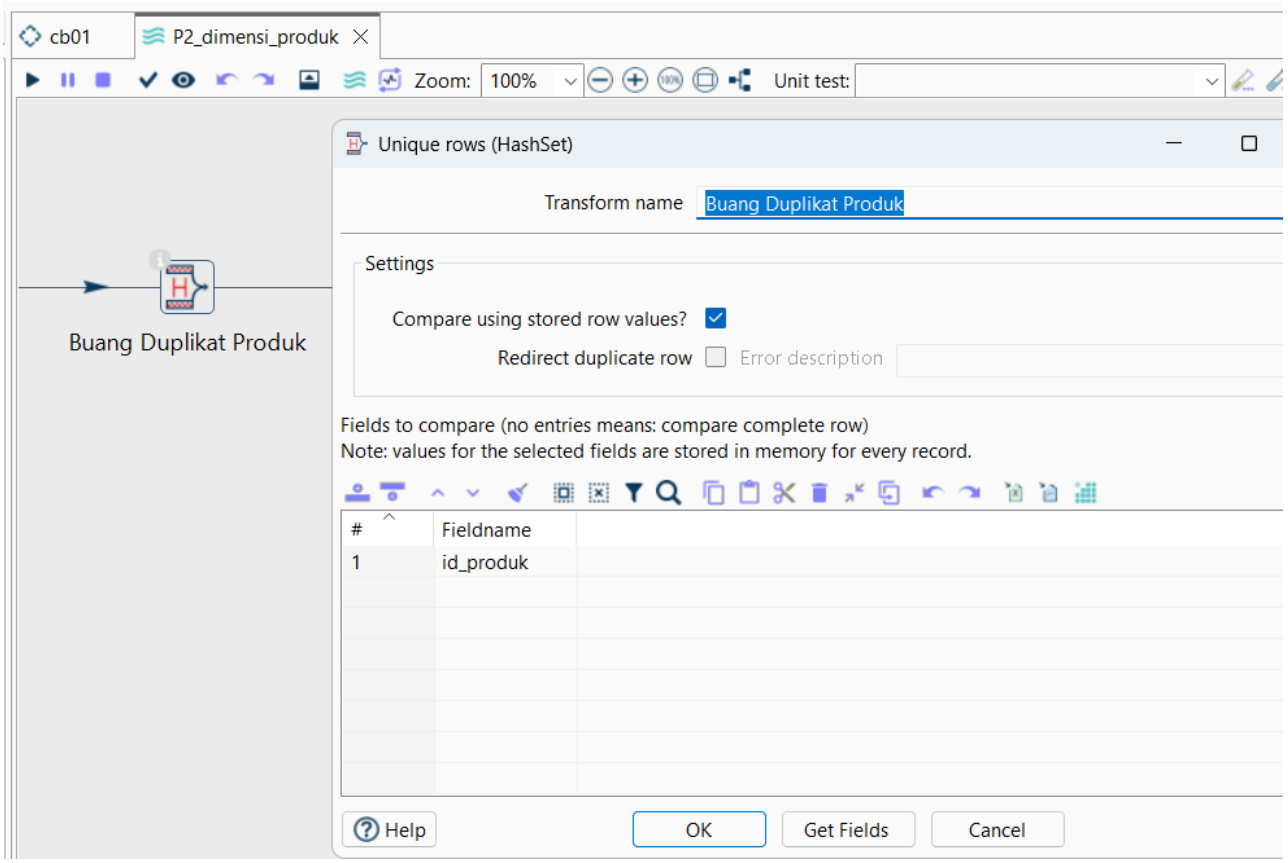
Sumber	Baris dibaca	Duplikat	Baris unik	Keterangan
penjualan.csv	2445	45	2400	Duplikat tersimpan di folder output
produk.xlsx	43	3	40	Duplikat: P013, P017, P024
pelanggan	180	0	180	id_pelanggan adalah primary key

Tabel pelanggan tidak memiliki duplikat karena id_pelanggan merupakan primary key di basis data sumber. Langkah ini tetap dipasang agar ketiga pipeline memiliki pola yang seragam dan tetap aman jika data sumber berubah.

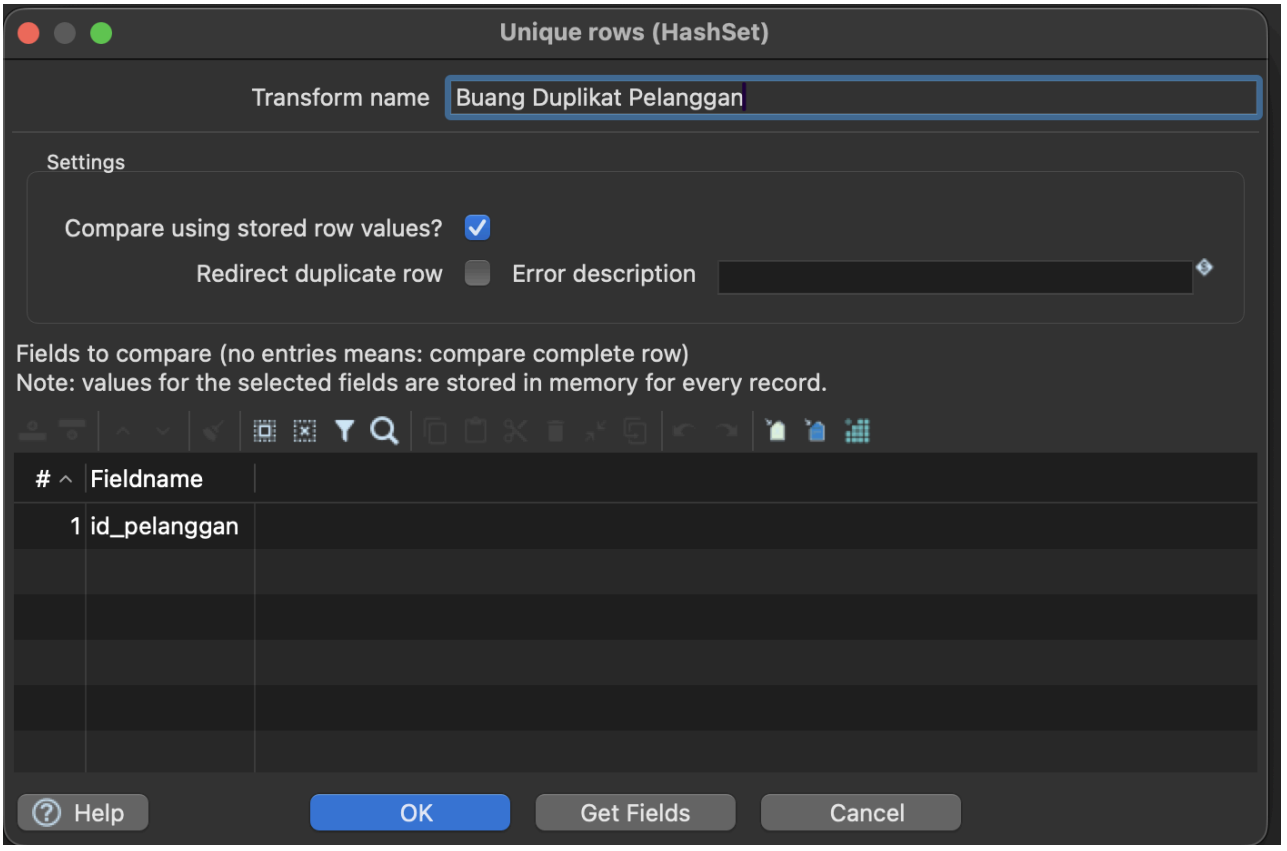
Gambar 2.3.2. (A) Transform unique rows membersihkan duplikat pada transaksi



Gambar 2.3.2. (B) Transform unique rows membersihkan duplikat pada produk



Gambar 2.3.2. (C) Transform unique rows membersihkan duplikat pada pelanggan

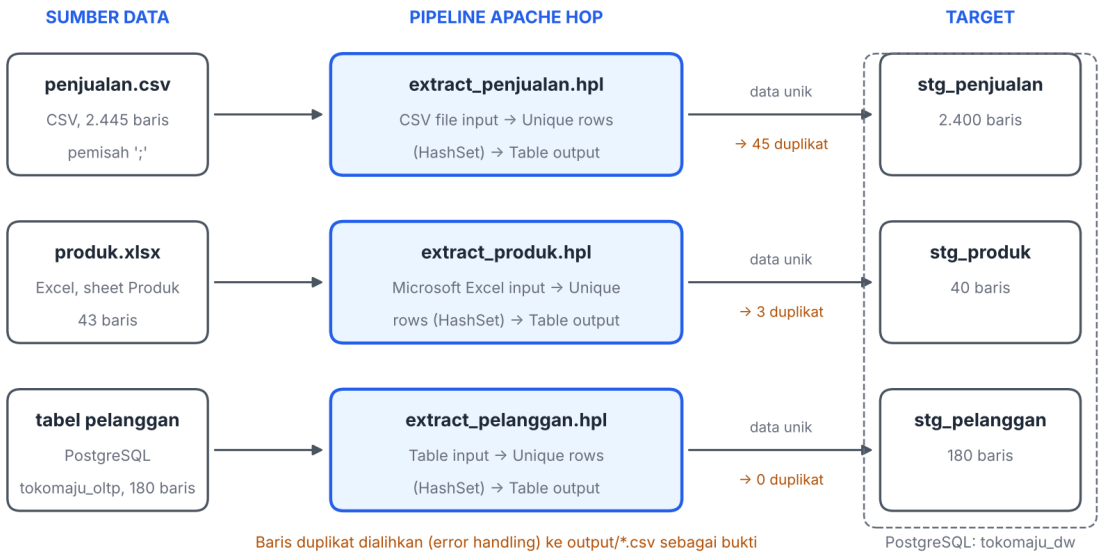


2.3.3. Arsitektur Pipeline

Arsitektur pipeline terdiri atas tiga pipeline dengan pola yang sama, yaitu transform input, Unique rows (HashSet), dan Table output. Ketiga berkas disimpan di folder pipelines dengan nama extract_penjualan.hpl, extract_produk.hpl, dan extract_pelanggan.hpl.

Pipeline extract_penjualan membaca berkas penjualan.csv, membuang transaksi kembar, mengalihkan baris duplikat ke berkas bukti, lalu memuat 2400 baris ke stg_penjualan. Pipeline extract_produk membaca master produk dari Excel, membuang id produk kembar, lalu memuat 40 baris ke stg_produk. Pipeline extract_pelanggan membaca tabel pelanggan dari basis data sumber lalu memuat 180 baris ke stg_pelanggan. Pada tahap lanjutan, ketiga pipeline akan dirangkai dalam satu workflow bersama pipeline pembersihan data dan pemuatan skema bintang.

Gambar 2.3.3. Arsitektur pipeline ekstraksi dari tiga sumber ke tabel staging



3. PEMBAGIAN TUGAS

Tabel 3. Pembagian Tugas Anggota

Ahsanta Khalqi Imany	- Mengatur lingkungan macOS, membangun tahap Extract dari 3 sumber data berbeda, dan menerapkan pembersihan duplikat (Unique Rows).
Pramudhia Ananda Kresna	- Mengonfigurasi basis data PostgreSQL (oltp & dw), membuat skrip environment JSON, serta merancang tabel staging.
Alfaril Dzaky Praptana	- Menyusun latar belakang teoretis, sejarah, lisensi, arsitektur, serta ringkasan komponen utama Apache Hop pada Bab 1.
Muhammad Faza Husain Baihaqi	- Menyiapkan spesifikasi perangkat Windows serta mendokumentasikan instalasi JDK, PostgreSQL, dan Apache Hop 2.19.0.
Muhammad Syihabuddin Syauqi	- Melakukan demo video instalasi konfigurasi percobaan

4. PENGGUNAAN AI

Tabel 4.1. Bagian yang dibantu AI

Bagian	**Bentuk bantuan AI**	**Pemeriksaan oleh kelompok**
Subbab 2.2.4 dan 2.3	Panduan langkah konfigurasi project, environment, koneksi, dan pipeline di macOS	Setiap langkah dijalankan langsung di Hop
Subbab 2.4	Membantu membaca pesan error dan menyarankan solusi	Solusi dicoba sampai pipeline berhasil berjalan
Subbab 2.3.5	Menghitung jumlah duplikat dan masalah data dengan skrip	Dicocokkan dengan Transform Metrics Hop
Subbab 1.5, 1.6, dan 2.3	Menyusun draf teks dan diagram arsitektur	Dibaca, disunting, dan dilengkapi kelompok

5. DAFTAR PUSTAKA

Apache Hop. (2026). Download Apache Hop. https://hop.apache.org/download/

Apache Hop. (2026). Apache Hop requirements, installation and configuration. https://hop.apache.org/manual/next/installation-configuration.html

Apache Hop. (2022). Apache Hop graduates as a Top-Level Project. https://hop.apache.org/blog/2022/01/hop-graduation/

Apache Hop. (2026). If you know Kettle (Pentaho Data Integration). https://hop.apache.org/tech-manual/next/hop-vs-kettle/if-you-know-kettle.html